

Proyecto de Investigación

Procesamiento de Datos a Gran Escala

1.- Objetivos:

- Entender la importancia del uso de herramientas de Big Data en entornos empresariales, a fin de poder solucionar preguntas de negocio.
- Entender el paso a paso de un proyecto de procesamiento de datos para la generación de hallazgos de valor basado en la metodología CRISP-DM.
- Documentar la implementación de un clúster como infraestructura de procesamiento de grandes volúmenes de datos, a través de máquinas virtuales
- Realizar procesamiento de datos aplicado a un problema real.

2.- Estructura del Proyecto:

Se deben realizar 2 entregas que forman parte de un proyecto analítico basado en la metodología CRISP-DM, donde se usen herramientas de Big Data como Apache Spark, logrando solucionar preguntas de negocio que resulten durante el proceso. Si bien el proyecto girará en mayor medida en los conceptos de procesamiento de datos, se abordarán temas relacionados a la construcción de modelos de aprendizaje de máquina y planteamiento de problemas de negocio

3.- Calificación

Cada una de las entregas será calificada a partir del documento (70%), más una sustentación oral de la entrega (30%). Esta sustentación tendrá los siguientes límites de tiempo:

- **Entrega 1:**
 - Documento (70%)
 - Presentación oral (30%): Tiempo 15 minutos
- **Entrega 2:**
 - Documento (70%)
 - Presentación oral (30%): Tiempo 15 minutos

4. Entrega 1: Entendimiento del negocio y entendimiento de los datos.

Esta entrega está enfocada a entender el negocio y los datos que se usarán para la elaboración del proyecto. Consiste en un caso de negocio, en el cual ustedes son el equipo de consultores contratados por el Ministerio de Educación para crear un plan de acción, basado en procesamiento de datos, y mejorar algunos indicadores territoriales de interés para el equipo de gobierno.

Los indicadores que más aquejan al equipo de gobierno son los resultados de

ICFES 11 con relación al servicio de internet por municipio, por lo que se les han suministrado los siguientes conjuntos de datos, con la finalidad de desarrollar un proyecto analítico que permita generar un plan de acción para mejorar estos indicadores (Los datos proporcionados son orientativos, su equipo de trabajo puede involucrar o cambiar según sus requerimientos/necesidades):

- Datos del servicio de internet por municipio: [vinculo](#)
- Datos de pobreza por municipio: [vinculo](#)
- Datos de ICFES generales: [vinculo](#)
- Datos de niveles de educación por municipio: [vinculoA](#), [vinculoB](#)
- Cualquier otro enlace con datos gubernamentales históricos que desee añadir para mejorar la contextualización del estudio de negocio.

En los numerales a continuación, se presentan los elementos que deben ser desarrollados en la primera entrega:

1. Entendimiento del negocio: en este apartado se espera que se presente un contexto general de la situación en los municipios seleccionados, como también algunos indicadores macroeconómicos de interés que consideren apropiados. Además se espera que se describa el objetivo de negocio (objetivo del equipo de consultoría).
2. Selección de los datos a utilizar: en este apartado se deben listar los conjuntos de datos que se usarán durante el proyecto, explicando la razón de esta selección basada en el objetivo de negocio (objetivo del equipo de consultoría).

Nota: Los conjuntos de datos seleccionados en la primera entrega pueden ser cambiados para la segunda de ser necesario.

3. Colección y descripción de datos: en este apartado se espera que se realice la carga de los datos a utilizar en ambiente de trabajo Apache (clúster spark) y se describan los datos según los siguientes elementos:
 - a. Tipos de datos.
 - b. Comprensión del significado de cada atributo.
 - c. Descripción general del contenido de los conjuntos de datos.
4. Exploración de los datos: en este apartado se espera que se presente los estadísticos descriptivos, gráficas, tablas agregadas, etc., que faciliten el entendimiento la estructura y comportamiento de los datos. Se espera que al menos se presenten 8 elementos de análisis (considerando gráficas, tablas, descriptivos).
5. Reporte de calidad de datos: en este apartado se presenta el conteo de valores faltantes para las tablas de datos (en caso de contar con valores faltantes) se deben proponer técnicas para poder tratar estos valores faltantes.

6. Planteamiento de preguntas sobre los datos: en este apartado se espera que se establezcan mínimo 8 preguntas de negocio relacionadas a los datos; a las que se le dará respuesta en la entrega 2 del proyecto. Un ejemplo de pregunta de negocio puede ser: ¿Cuál es la cobertura neta secundaria de los municipios seleccionados?
Nota: En esta entrega no se le debe dar respuesta a las preguntas planteadas.
7. Filtros, limpieza y transformación inicial: En este apartado se espera que se presenten algunas transformaciones y filtros realizadas sobre los datos, como también los procesos de limpieza que se van a realizar. Un ejemplo de transformación sería estandarizar la cantidad de servicio de internet por la cantidad de individuos que viven en el municipio; un ejemplo de filtrado será la eliminación de registros alterados/atípicos y un ejemplo de limpieza sería la imputación de valores faltantes por la media de dicha variable. Nota: Se espera que se presente un avance en este apartado, pero el proceso completo será entregado en la segunda entrega.

4.1. Bono de 0.5 sobre lo obtenido en la entrega

Los siguientes apartados se evaluarán como un bono de +0.5 (+0.25 cada uno) sobre la entrega realizada:

- Realizar una ejecución de proceso web scraping para extraer la información de la población contenida en la tabla del siguiente [vínculo](#) y generar al menos un gráfico o tabla con estos datos.
- Extraer información climática contenida en la siguiente [API](#) y generar al menos un gráfico o tabla con estos datos.

5.- Entrega 2: Preparación de datos, modelado y presentación de resultados

Una vez se cuenta con un entendimiento profundo del problema de negocio y los datos, se debe culminar su limpieza y transformación para responder las preguntas de negocio previamente planteadas, como también aplicar modelos de aprendizaje de máquina para enriquecer el ejercicio. Los numerales que forman parte de la segunda entrega son los siguientes:

1. Filtros y transformaciones: en este apartado se espera que se presenten las transformaciones finales y filtros aplicados sobre los datos que se vienen trabajando, se espera que se realicen al menos 2 filtros y 3 transformaciones., como también la justificación de estos procedimientos.
2. Respuesta a preguntas de negocio planteadas: en este apartado se espera que se presenten las tablas y visuales que responden las preguntas de negocio planteadas con anterioridad, estas respuestas

deben presentar un punto de contacto con el entendimiento de negocio descrito en la primera entrega.

3. Selección de técnicas de aprendizaje de máquina: en este apartado se espera que se seleccione 1 técnica de aprendizaje de máquina supervisado y 1 técnica de aprendizaje de máquina no supervisado, que se aplicará sobre los datos que se vienen trabajando. Se espera que se justifique esta selección en miras del objetivo de negocio del ejercicio.
4. Preparación de datos para modelado: este apartado se divide en las siguientes tareas.
 - a. Eliminar características fuertemente correlacionadas: en este apartado se espera que se calcule la correlación entre las variables y se eliminen aquellas fuertemente correlacionadas si es el caso.
 - b. Normalización de variables numéricas: en este apartado se espera que se realice una normalización de datos si es el caso.
 - c. Selección de variables según criterio de negocio: en este apartado se espera que se describa el grupo de variables que se usarán para la construcción de las técnicas seleccionadas.
5. Aplicar las técnicas seleccionadas sobre los datos con Mlib sobre el clúster Spark para procesamiento de Alto Volumen de Datos sobre los datos con Mlib sobre el Cluster de Alto Rendimiento Apache Spark, implementado por sus equipos.
6. Aplicar las métricas que mejor se adapten al problema. Nota: Se espera que se realicen pruebas con diferentes parámetros para cada una de las técnicas.

5.1. Bono de 0.5 sobre lo obtenido en la entrega

Se evaluará como un bono de +0.5 (+0.25 cada uno) sobre la entrega realizada:

1. Construir 1 modelo de Aprendizaje profundo (Redes neuronales) con los datos que se han venido utilizando.
2. Diseñar e implementar una solución de despliegue de los resultados de la fase de modelado. Tienen libertad en cuanto al tipo de implementación y la herramienta a utilizar

6.- Reglas y condiciones de entrega

- Todas las entregas deben ser hechas en formato .pdf. junto con el cuaderno de trabajo en un repositorio de su preferencia (los cuadernos de trabajo deben estar documentados y membretados).
- La persona que sea expulsada de un grupo con justa causa tendrá una nota de 0.0 en las siguientes entregas y no podrá unirse a otro grupo.

- Revisar con detenimiento ortografía y redacción para evitar reducción en la nota de la entrega.
- Bonos adicionales: Los grupos que realicen las referencias con una herramienta bibliográfica (Zotero/Mendeley) tendrán +0.1 en la entrega final. Adicional, el repositorio debería tener su respectivo **Readme**, se considera +0.05 sobre la entrega final