

BRECHA DIGITAL Y RESULTADOS SABER 11

Pipeline distribuido sobre Apache Hadoop + Spark

Proyecto de Investigación — Entrega 2

Grupo: REST pAPIs

Juan Camilo Carvajal · Juan Pablo Cañón · Juan David Rincón · Tatiana Vivas

Procesamiento de Datos a Gran Escala

Pontificia Universidad Javeriana · Facultad de Ingeniería

Mayo 2026 · Prof. Fabián Pallares

Agenda

- Contexto del negocio y problema a resolver
- Datos: ICFES, MinTIC, Sisbén, MEN — descripción y exploración
- Infraestructura del cluster Hadoop + Spark
- Arquitectura medallion Bronze → Silver → Gold
- Hallazgos clave del análisis exploratorio
- Modelos supervisados y no supervisado con MLlib
- Bono: Red Neuronal MLP a nivel estudiante
- Recomendaciones de política pública

El problema de negocio

Somos consultores del Ministerio de Educación Nacional

¿Por qué importa?

- La diferencia de puntaje Saber 11 entre departamentos llega a 60 puntos.
- Brecha urbano-rural promedio: ~26 puntos.
- Inversión en conectividad ha crecido, pero el impacto académico es heterogéneo.

Pregunta central

¿Qué tanto del rendimiento Saber 11 se explica por la brecha digital, controlando por pobreza, cobertura educativa y geografía?

Producto esperado: evidencia cuantitativa + modelos + recomendaciones focalizadas.

Datos utilizados

Cuatro fuentes oficiales del Estado colombiano (datos.gov.co)

Dataset	Fuente	Filas	Tamaño CSV	Grano
ICFES Saber 11	ICFES	7,109,704	3.5 GB	Estudiante
Internet Fijo	MinTIC	2,795,052	384 MB	Mpio × Año × Trimestre × Proveedor
Sisbén Personas	DNP	4,465,955	937 MB	Persona
MEN Educación	MinEducación	15,707	5 MB	Municipio × Año

14.4 millones de registros · joins por código DANE de municipio · cobertura 2011-2024

14.4 M

registros integrados

4.8 GB

datos crudos procesados

1,098

municipios cubiertos

Dataset 1: ICFES Saber 11

La variable objetivo del proyecto · 7.1M estudiantes · 51 columnas

ICFES — Resultados únicos Saber 11

Fuente: ICFES (datos.gov.co)

7,109,704 filas

3.5 GB

Atributos clave


- PUNT_GLOBAL: puntaje global (0-500, variable objetivo)
- PUNT_Lectura, MATEMATICAS, NATURALES, SOCIALES, INGLES
- FAMI_TIENEINTERNET, FAMI_TIENECOMPUTADOR
- FAMI_ESTRATOVIVIENDA (1-6)
- COLE_AREA_UBICACION (Urbano/Rural)
- COLE_DEPTO/MCPIO_UBICACION + códigos DANE
- PERIODO (formato YYYY)

Cobertura

- Periodo: 2013 — 2024 (24 semestres)
- Cubre todos los departamentos del país
- Mezcla colegios oficiales, no oficiales y bilingües
- Información socioeconómica del hogar
- Información del colegio y la jornada
- Información geográfica completa

ICFES: distribución del puntaje global

Lo primero que miramos: la forma de la variable objetivo




Observaciones clave

- Distribución aprox. normal centrada en 250 pts
- Desviación amplia, rango 0–500
- Concentración anómala en cero: registros no presentados (~2.6M)
- La cola superior corresponde a estudiantes de alto rendimiento

Decisión: descartar registros con `PUNT_GLOBAL` nulo o ≤ 0 (~37% de las filas).

ICFES: la geografía cuenta

Puntaje promedio por departamento (top 20, mínimo 1,000 estudiantes)




Patrón territorial

- Bogotá, Santander, Boyacá y Antioquia lideran
- Departamentos de frontera y rurales en la cola
- Diferencia entre extremos: >30 puntos
- Brecha estructural enorme en escala Saber 11

Esta heterogeneidad justifica el análisis por municipio (no nacional).

ICFES: internet en el hogar × zona

Primera intuición de la pregunta central



Hallazgo preliminar

- En URBANO y RURAL: con internet > sin internet
- Brecha urbana ~ 13 puntos
- Brecha rural similar en magnitud
- 'SIN INFORMACION' se comporta como 'sin internet'

Esto motiva la binarización TIENE_INTERNET_BIN y la categoría explícita 'SIN INFORMACION'.

Dataset 2: Internet Fijo (MinTIC)

Conectividad por municipio · 2.8M registros · 12 columnas

MinTIC — Internet Fijo: accesos por tecnología y segmento

Fuente: MinTIC (datos.gov.co)

2,795,052 filas

384 MB

Atributos clave


- AÑO, TRIMESTRE
- COD_DEPARTAMENTO, COD_MUNICIPIO (códigos DANE)
- PROVEEDOR (ISP)
- SEGMENTO (residencial / corporativo / otro)
- TECNOLOGIA (FTTH, HFC, XDSL, etc.)
- VELOCIDAD_BAJADA, VELOCIDAD_SUBIDA (Mbps)
- NUM_ACCESOS (conteo de accesos)

Particularidades técnicas

- Coma decimal en velocidades (locale es-CO): '8,00'
- Carácter Ñ en 'AÑO' rompe selects en Spark
- Espacio en 'No DE ACCESOS' (renombrado)
- 82 K grupos de duplicados exactos detectados
- Grano fino: 1 fila por (mpio, trim, prov, tec)

Internet Fijo: evolución 2014–2024

Masificación sostenida con aceleración pos-pandemia




Patrones observados

- Crecimiento sostenido
- Salto 2020-2021 (COVID-19)
- Reporte parcial en 2014-2015
- Saturación incipiente en 2024

Internet Fijo: distribución por tecnología

Coexistencia de infraestructura tradicional y fibra óptica



Lectura técnica

- FTTH (fibra) creciendo
- HFC y Cable dominantes
- XDSL en declive
- Justifica usar VELOCIDAD como feature: no todas las tecnologías son iguales

Dataset 3: Sisbén Personas (DNP)

Contexto socioeconómico · 4.5M personas · 48 columnas

DNP — Sisbén Personas	<i>Fuente: DNP (datos.gov.co)</i>	4,465,955 filas	937 MB
------------------------------	-----------------------------------	-----------------	--------

Atributos clave


- cod_mpio (código DANE)
- Grupo: A (más vulnerable) → D (menos)
- Nivel + Clasificación (e.g. B2, C3)
- ZONA (1=urbana, 2=rural)
- FEX (factor de expansión)
- I1..I15: 15 indicadores binarios de privación
- Persona-Hogar identificadores

Decisión clave

- Grano fino: persona individual
- Para joins necesita AGREGACIÓN a municipio
- 4.5M personas → 1,099 municipios
- Métricas derivadas:
 - - idx_privacion = $\sum \text{avg}(I1..I15)$
 - - pct_grupo_A, pct_grupo_B, etc.
 - - pct_rural, n_personas, n_hogares

Sisbén: distribución por grupos

Promedio por municipio de personas en cada grupo



Concentración en vulnerabilidad


- Grupo A (más vulnerable): casi 50% en promedio
- Grupo B: ~30%
- Grupo C: ~16%
- Grupo D (menos vulnerable): ~5%

El Sisbén focaliza su registro en la población objetivo de programas sociales.

Esto debe considerarse al comparar municipios.

Sisbén × ICFES: privación vs Saber 11

Primer cruce multi-fuente · 1 punto = 1 municipio-año



Hallazgos visuales

- Pendiente claramente negativa
- Color rojo (rural) en la zona pobre
- Color verde (urbano) en la zona próspera
- Geografía, pobreza y rendimiento se mueven juntos

Dataset 4: MEN Educación Municipal

Indicadores estructurales del sistema educativo · 15.7K filas · 41 columnas

MEN — Estadísticas en educación preescolar, básica y media	<i>Fuente: MinEducación (datos.gov.co)</i>	15,707 filas	5 MB
---	--	--------------	------

Atributos clave


- AÑO, CÓDIGO_MUNICIPIO, CÓDIGO_DEPARTAMENTO
- POBLACIÓN_5_16 (universo escolar)
- COBERTURA_NETA (total y por nivel)
- COBERTURA_BRUTA (total y por nivel)
- TASA_MATRICULACIÓN_5_16
- DESERCIÓN, APROBACIÓN, REPROBACIÓN, REPITENCIA
- SEDES_CONECTADAS_A_INTERNET

Particularidades

- Grano: municipio × año (panel temporal)
- Cobertura: 2011 — 2024 (14 vigencias)
- 1,124 municipios cubiertos
- Acentos en nombres de columna (requiere slugify)
- Porcentajes como texto: '56.11%' (requiere parsing)
- Dos archivos byte-idénticos (verificado MD5)

MEN: evolución de la cobertura neta

Brecha estructural entre niveles educativos



Brecha por nivel

- Primaria: 70–80%
- Secundaria: 60–70%
- Media: solo 40–45%
- El sistema pierde estudiantes en el tránsito a secundaria y media

Infraestructura del cluster

Cluster propio Hadoop + Spark, no Databricks ni cloud

Hardware

- 1 NameNode + 3 Workers
- 16 cores totales (4 por worker)
- 42 GB RAM total
- Rocky Linux 9

Software

- Hadoop 3.3.6 (HDFS, replicación 3)
- Spark 3.5.2 standalone
- PySpark 3.5.2 + JupyterLab 4.5
- Spark MLlib para todos los modelos

Spark Master at spark://spark-master:7077

URL: spark://spark-master:7077
Alive Workers: 4
Cores in use: 16 Total, 16 Used
Memory in use: 41.6 GiB Total, 32.0 GiB Used
Resources in use:
Applications: 1 Running, 47 Completed
Drivers: 0 Running, 0 Completed
Status: ALIVE

Workers (4)

Worker Id	Address	State	Cores	Memory	Resources
worker-20260325082607-10.43.97.208-43929	10.43.97.208:43929	ALIVE	4 (4 Used)	10.4 GiB (8.0 GiB Used)	
worker-20260325082643-10.43.97.198-34381	10.43.97.198:34381	ALIVE	4 (4 Used)	10.4 GiB (8.0 GiB Used)	
worker-20260325082651-10.43.97.163-39027	10.43.97.163:39027	ALIVE	4 (4 Used)	10.4 GiB (8.0 GiB Used)	
worker-20260325082714-10.43.97.164-41607	10.43.97.164:41607	ALIVE	4 (4 Used)	10.4 GiB (8.0 GiB Used)	

Running Applications (1)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
app-20260523134857-0047	(kill) Entrega2-ML-Regresion	16	4.0 GiB		2026/05/23 13:48:57	estudiante	RUNNING	3.4 min


Completed Applications (47)

Application ID	Name	Cores	Memory per Executor	Resources Per Executor	Submitted Time	User	State	Duration
app-20260523134114-0046	Entrega2-EDA	16	3.0 GiB		2026/05/23 13:41:14	estudiante	FINISHED	57 s
app-20260522110651-0045	EDA-Figs	16	3.0 GiB		2026/05/22 11:06:51	estudiante	FINISHED	34 s
app-20260522103448-0044	Entrega2-Bono-MLP	16	4.0 GiB		2026/05/22 10:34:46	estudiante	FINISHED	18 min
app-20260522085215-0043	Entrega2-Bono-MLP	16	4.0 GiB		2026/05/22 08:52:15	estudiante	FINISHED	1.6 h
app-20260522084500-0042	Entrega2-Bono-MLP	16	4.0 GiB		2026/05/22 08:45:00	estudiante	FINISHED	6.3 min
app-20260522082359-0041	Entrega2-ML-KMeans	16	3.0 GiB		2026/05/22 08:23:59	estudiante	FINISHED	1.1 min


Spark Master UI (puerto 8080)

Evidencia: HDFS NameNode UI

Sistema de archivos distribuido con replicación 3



Pestaña Datanodes: los 3 workers vivos




Browse /usr/proyecto/ — estructura medallion

44.8 GB de capacidad total · 15.8 GB usados · replicación factor 3

Evidencia: Spark Application UI


Ejecución distribuida sobre 4 workers



The screenshot shows the Spark UI Jobs tab. It displays a table with columns: Job ID, Description, Submitted, Duration, Stages: Succeeded/Total, and Tasks (for all stages): Succeeded/Total. A single job is listed with ID 0, description 'sum at /tmp/keep_spark_alice.py:10', submitted at 2020/05/23 14:51:22, duration of 5 s, and 1/1 stages. The tasks column shows a progress bar for 32/32 tasks.

Job ID	Description	Submitted	Duration	Stages: Succeeded/Total	Tasks (for all stages): Succeeded/Total
0	sum at /tmp/keep_spark_alice.py:10	2020/05/23 14:51:22	5 s	1/1	32/32


Jobs



The screenshot shows the Spark UI Stages tab. It displays a table with columns: Stage ID, Description, Submitted, Duration, Tasks: Succeeded/Total, Input, Output, Shuffle Read, and Shuffle Write. A single stage is listed with ID 0, description 'sum at /tmp/keep_spark_alice.py:10', submitted at 2020/05/23 14:51:23, duration of 4 s, and 32/32 tasks. The tasks column shows a progress bar for 32/32 tasks.

Stage ID	Description	Submitted	Duration	Tasks: Succeeded/Total	Input	Output	Shuffle Read	Shuffle Write
0	sum at /tmp/keep_spark_alice.py:10	2020/05/23 14:51:23	4 s	32/32				

Stages paralelos



The screenshot shows the Spark UI Executors tab. It displays a summary table with columns: RDD Blocks, Storage Memory, Disk Used, Cores, Active Tasks, Failed Tasks, Complete Tasks, Total Tasks, Task Time (GC Time), Input, Shuffle Read, Shuffle Write, Excluded, Logs, Thread Dump, Add Time, and Remove Time. The table lists 6 executors, including the driver and 5 workers.

Executor ID	Address	Status	RDD Blocks	Storage Memory	Disk Used	Cores	Active Tasks	Failed Tasks	Complete Tasks	Total Tasks	Task Time (GC Time)	Input	Shuffle Read	Shuffle Write	Excluded	Logs	Thread Dump	Add Time	Remove Time
driver	spark-master:41371	Active	0	0.0 B / 912.3 MB	0.0 B	0	0	0	0	0	10 min (5.3 s)	0.0 B	0.0 B	0.0 B	0		Thread Dump	2020-05-23 14:51:21	-
0	10.43.97.208:38545	Active	0	0.0 B / 912.3 MB	0.0 B	2	0	0	15	15	9 s (22.0 ms)	0.0 B	0.0 B	0.0 B	0	stdout stderr	Thread Dump	2020-05-23 14:51:23	-
1	10.43.97.208:40371	Active	0	0.0 B / 912.3 MB	0.0 B	2	0	0	13	13	4 s (22.0 ms)	0.0 B	0.0 B	0.0 B	0	stdout stderr	Thread Dump	2020-05-23 14:51:23	-
2	10.43.97.163:33343	Active	0	0.0 B / 912.3 MB	0.0 B	2	0	0	2	2	5 s (36.0 ms)	0.0 B	0.0 B	0.0 B	0	stdout stderr	Thread Dump	2020-05-23 14:51:24	-
3	10.43.97.163:34059	Active	0	0.0 B / 912.3 MB	0.0 B	2	0	0	2	2	5 s (36.0 ms)	0.0 B	0.0 B	0.0 B	0	stdout stderr	Thread Dump	2020-05-23 14:51:25	-
4	10.43.97.164:45675	Active	0	0.0 B / 912.3 MB	0.0 B	2	0	0	0	0	0.0 ms (0.0 ms)	0.0 B	0.0 B	0.0 B	0	stdout stderr	Thread Dump	2020-05-23 14:51:26	-
5	10.43.97.164:34905	Active	0	0.0 B / 912.3 MB	0.0 B	2	0	0	0	0	0.0 ms (0.0 ms)	0.0 B	0.0 B	0.0 B	0	stdout stderr	Thread Dump	2020-05-23 14:51:26	-
6	10.43.97.198:35601	Active	0	0.0 B / 912.3 MB	0.0 B	2	0	0	0	0	0.0 ms (0.0 ms)	0.0 B	0.0 B	0.0 B	0	stdout stderr	Thread Dump	2020-05-23 14:51:26	-

Executors (workers reales)

Cada job se descompone en stages paralelos asignados a los executors del cluster.

Pipeline Bronze → Silver → Gold

Arquitectura medallion en HDFS · una sola vista minable alimenta los modelos

Capa	Qué contiene	Tamaño en HDFS
Bronze (CSV)	Datos crudos descargados	4.7 GB
Bronze Parquet	Misma data, columnar + snappy	386 MB
Silver	Limpia, tipada, geo normalizado	113 MB
Gold panel	Joins (mpio × año) = vista minable	1.5 MB
Models	4 modelos persistidos	2 MB

Compresión obtenida

12×

CSV → Parquet snappy


7,004

filas vista minable
(municipio × año)

Una sola tabla unificada (44 columnas) alimenta EDA y los 4 modelos de ML.

Hallazgo 1: La conectividad sí pesa

Pero menos de lo que se suele asumir



$r = +0.41$

correlación municipal

internet $\leftrightarrow$ puntaje

+22 pts

diferencia entre municipios con

ALTA vs BAJA penetración de internet

Saber 11 $\approx$ 250 (cuartil 4 internet)

Saber 11 $\approx$ 228 (cuartil 1 internet)

Hallazgo 2: La pobreza incide incluso controlando por internet

Análisis estratificado por cuartil de conectividad

Correlación (privación, puntaje) DENTRO de cada cuartil de internet:


Cuartil internet	N° mpio-año	Corr (privación, puntaje)	Puntaje promedio
Q1 (bajo)	1,661	-0.461	234.1
Q2	1,702	-0.510	237.2
Q3	1,745	-0.521	239.2
Q4 (alto)	1,805	-0.404	252.2
Sin controlar	6,913	-0.520	—

Conclusión: invertir solo en conectividad NO es suficiente.

La política debe combinar acceso digital + intervención socioeconómica.

Hallazgo 3: El computador en casa eleva TODAS las áreas

Nivel estudiante (4.5M registros del Silver ICFES)



Diferencia con vs sin computador:

- Inglés: +8.3 pts
- Matemáticas: +6.5 pts
- Sociales: +6.4 pts
- Naturales: +5.9 pts
- Lectura: +5.7 pts

El efecto más fuerte está en Inglés:

área que requiere práctica autónoma con recursos digitales especializados.

Hallazgo 4: Municipios anómalos

Alta conectividad pero bajo rendimiento académico

10

municipios anómalos
detectados (año 2022)

5 / 10

concentrados en Antioquia

5.1 %

deserción promedio
(vs 4.1 % del resto)

Criterio de detección

- Conectividad $\geq$ percentil 75 (> 62.4 % de hogares con internet)
- Puntaje Saber 11 $\leq$ percentil 25 (< 223.9 puntos)
- Patrón: deserción superior + privación alta $\rightarrow$ infraestructura por sí sola no basta

Estos 10 municipios son target prioritario para análisis cualitativo posterior.

Modelos supervisados: Regresión Lineal vs Decision Tree

Predicción del puntaje promedio municipal · 27 combinaciones de hiperparámetros

Modelo	TRAIN R ²	TEST R ²	TEST MAE	TEST RMSE
Regresión Lineal (default)	0.4169	0.4067	12.31	16.28
Decision Tree (default)	0.6709	0.5004	11.21	14.94
LR mejor del grid	—	0.4070	—	16.27
DT mejor del grid (ganador)	0.5857	0.5214	—	14.62

Importancia de variables (DT ganador)

- idx_privacion: 48.3 %
- pct_internet_icfes: 23.3 %
- pct_rural_sisben: 6.3 %
- resto < 5 % cada una



Decision Tree gana por capturar interacciones no lineales.

Privación + Conectividad explican el 72 % de la importancia total.

Ambos modelos persistidos en /usr/proyecto/models/ · recargables con .load()

K-Means: selección del número de clusters

Método del codo (WCSS) + coeficiente de silueta




Lectura

- Silueta máx en $k=2$ (0.449)
- WCSS sin codo marcado
- $k=2$ es la elección consistente
- Dos clusters → dos perfiles diferenciados de política pública

K-Means: dos tipologías municipales

Snapshot 2022 · 1,098 municipios clasificados




Dos perfiles claramente diferenciados:

	Cluster 0	Cluster 1
# municipios	603	495
Puntaje promedio	227.6	251.4
% internet	38.6 %	64.2 %
Idx privación	4.39	3.23

Cluster 0 = grupo objetivo del plan de acción.

Bono: Red Neuronal MLP

Clasificación a nivel estudiante individual con Spark MLlib distribuido



Limitación: desbalance de clases (66 % MEDIO) → recall bajo en ALTO/BAJO.

Trabajo futuro: SMOTE o reformulación binaria para alerta temprana.

Setup

- 4,500,067 estudiantes (Silver ICFES)
- Arquitectura: [76 → 32 → 3]
- Clases: BAJO / MEDIO / ALTO
- 76 features (categóricas one-hot + binarias)
- Entrenamiento distribuido en 4 workers

Métricas de TEST (898 K estudiantes)

Accuracy	Precision	Recall	F1
0.6899	0.6715	0.6899	0.6335

Recomendaciones para el Ministerio de Educación

Plan de acción derivado del análisis cuantitativo

1

Focalizar inversión en Cluster 0

603 municipios con baja conectividad + alta privación.

Intervención integral, no solo digital.

2

Conectividad rural de alto nivel

En Q4 de internet, los rurales igualan a los urbanos.

Meta: > 50 % en rurales del Cluster 0.

3

Computador + acompañamiento pedagógico

Efecto positivo comprobado en TODAS las áreas.

Máximo en inglés (+8.3 pts).

4

Sistema de alerta temprana

Modelo DT ($R^2=0.52$) + MLP (acc 69 %)

operativizables en un tablero territorial.

Gracias

¿Preguntas?

Grupo REST pAPIs · Entrega 2 · Brecha digital y Saber 11

github.com/ProcesamientoDatos2610/proyecto2